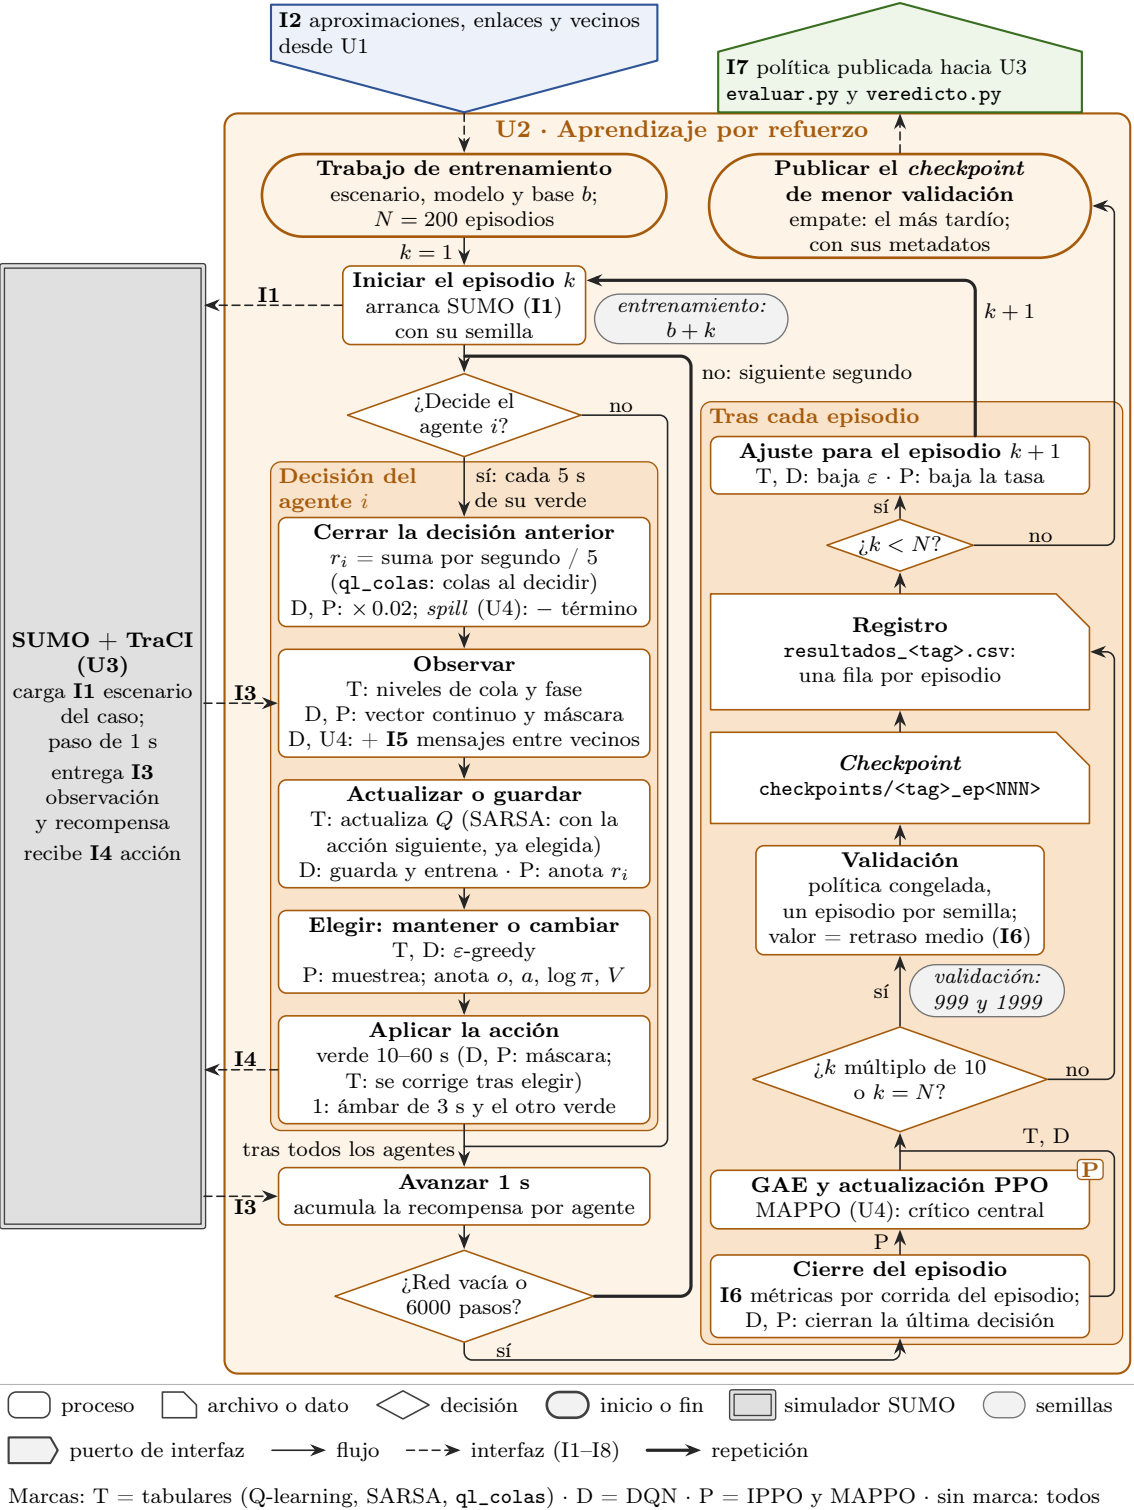

I2 aproximaciones, enlaces y vecinos desde U1
I7 política publicada hacia U3
evaluar.py y veredicto.py
U2 · Aprendizaje por refuerzo
Trabajo de entrenamiento
escenario, modelo y base b;
N = 200 episodios
Publicar el checkpoint de menor validación
empate: el más tardío; con sus metadatos
k = 1
Iniciar el episodio k
arranca SUMO (I1) con su semilla
entrenamiento: b + k
k + 1
I1
no: siguiente segundo
¿Decide el agente i?
no
sí: cada 5 s de su verde
Tras cada episodio
Ajuste para el episodio k + 1
T, D: baja ε · P: baja la tasa
sí
¿k < N?
no
Decisión del agente i
Cerrar la decisión anterior
r_i = suma por segundo / 5
(ql_colas: colas al decidir)
D, P: × 0.02; spill (U4): − término
Registro
resultados_<tag>.csv:
una fila por episodio
SUMO + TraCI (U3)
carga I1 escenario del caso;
paso de 1 s
entrega I3 observación y recompensa
recibe I4 acción
I3
Observar
T: niveles de cola y fase
D, P: vector continuo y máscara
D, U4: + I5 mensajes entre vecinos
Checkpoint
checkpoints/<tag>_ep<NNN>
Actualizar o guardar
T: actualiza Q (SARSA: con la acción siguiente, ya elegida)
D: guarda y entrena · P: anota r_i
Validación
política congelada, un episodio por semilla;
valor = retraso medio (I6)
Elegir: mantener o cambiar
T, D: ε-greedy
P: muestrea; anota o, a, log π, V
sí
validación: 999 y 1999
¿k múltiplo de 10 o k = N?
no
I4
Aplicar la acción
verde 10–60 s (D, P: máscara;
T: se corrige tras elegir)
1: ámbar de 3 s y el otro verde
tras todos los agentes
T, D
P
GAE y actualización PPO
MAPPO (U4): crítico central
I3
Avanzar 1 s
acumula la recompensa por agente
P
Cierre del episodio
I6 métricas por corrida del episodio;
D, P: cierran la última decisión
¿Red vacía o 6000 pasos?
sí
proceso
archivo o dato
decisión
inicio o fin
simulador SUMO
semillas
puerto de interfaz
flujo
interfaz (I1–I8)
repetición
Marcas: T = tabulares (Q-learning, SARSA, ql_colas) · D = DQN · P = IPPO y MAPPO · sin marca: todos